



Condition Diffusion Model

这里记录了如何在扩散模型过程中加入条件的三种方式。

在扩散模型中，我们按照将条件注入到扩散模型的方式进行区分，可以分为：Vanilla Guidance, Classifier Guidance 以及 Classifier-Free Guidance。我们需要先理解一下为什么需要加入条件。假如我们在imagenet上训练了一个生成图像的无条件扩散模型，但是我们在推理的时候，我们想要生成一张小狗的图片，我们没有办法控制该扩散模型去生成指定类别的图像。

Vanilla Guidance (朴素引导)

Vanilla Guidance 是实现条件扩散模型最直观的方法。其核心思想是：将条件信息 y （如图像类别、文本描述）作为噪声预测模型 ϵ_θ 的一个额外输入。

具体而言，正如我们通过嵌入或注意力机制将时间步 t 的信息注入模型一样，我们可以用完全相同的方式（例如拼接、嵌入或交叉注意力）将任意条件 y 与噪声条件 x_t 和时间步 t 一同输入模型。因此，训练的目标是让模型学会预测基于条件的噪声： $\epsilon_\theta(x_t, t, y)$ 。

然而，Vanilla Guidance 存在一个关键局限是它缺乏对引导强度的显式控制。在训练阶段，模型学习了条件 y 和数据 x 的关联；但在推理采样时，我们无法动态调节条件对生成过程的影响力度。这意味着生成过程要么完全遵循条件，要么完全忽略条件，而无法在“生成质量与多样性”以及“条件遵从度”之间进行灵活的权衡。

Classifier Guidance

在学习之前，我们需要了解NCSN(Noise Condition Score Network)和扩散模型的联系，尤其是如何从去噪预测中推导出得分函数：

$$\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t) = -\frac{1}{\sqrt{1-\bar{\alpha}_t}} \epsilon_\theta(\mathbf{x}_t, t) \quad (1)$$

Classifier Guidance的思想是：标准扩散模型只学习数据分布 $q(x)$ ，无法控制生成结果的类别。为了实现“按类生成”(例如生成猫、狗)，我们可以使用一个额外的分类器来提供梯度信息，引导扩散过程朝目标类别方向演化。

我们要计算的是，在给定类别 y 的条件下， x_t 的得分函数，即：

$$\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t|y) \quad (2)$$

根据贝叶斯公式，得到：

$$q(\mathbf{x}_t|y) = \frac{q(y|\mathbf{x}_t)q(\mathbf{x}_t)}{q(y)} \quad (3)$$

$$\log q(\mathbf{x}_t|y) = \log q(y|\mathbf{x}_t) + \log q(\mathbf{x}_t) - \log q(y) \quad (4)$$

我们对 x_t 求梯度，得到：

$$\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t|y) = \nabla_{\mathbf{x}_t} \log q(y|\mathbf{x}_t) + \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t) \quad (5)$$

我们知道无条件得分可以表示为：

$$\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t) = -\frac{1}{\sqrt{1-\bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \quad (6)$$

而 $\nabla_{\mathbf{x}_t} \log q(y|\mathbf{x}_t)$ 可以通过训练一个分类器得到，其对数似然的梯度是：

$$\nabla_{\mathbf{x}_t} \log f_{\phi}(y|\mathbf{x}_t) \quad (7)$$

所以：

$$\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t|y) \approx -\frac{1}{\sqrt{1-\bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t) + \nabla_{\mathbf{x}_t} \log f_{\phi}(y|\mathbf{x}_t) \quad (8)$$

接下来我们需要将条件得分转化为新的噪声预测，我们前面提到：

$$\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t) = -\frac{1}{\sqrt{1-\bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \Rightarrow \epsilon_{\theta}(\mathbf{x}_t, t) = -\sqrt{1-\bar{\alpha}_t} \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t)$$

同样的，对于条件分布 $q(x_t|y)$ ，我们定义一个条件噪声预测器 $\tilde{\epsilon}_{\theta}(\mathbf{x}_t, t)$ ，使得：

$$\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t|y) = -\frac{1}{\sqrt{1-\bar{\alpha}_t}} \tilde{\epsilon}_{\theta}(\mathbf{x}_t, t) \quad (9)$$

将其代入上面的联合得分公式：

$$-\frac{1}{\sqrt{1-\bar{\alpha}_t}} \tilde{\epsilon}_{\theta}(\mathbf{x}_t, t) = -\frac{1}{\sqrt{1-\bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t) + \nabla_{\mathbf{x}_t} \log f_{\phi}(y|\mathbf{x}_t) \quad (10)$$

两边同时乘一个 $-\sqrt{1-\bar{\alpha}_t}$ ，得到：

$$\tilde{\epsilon}_{\theta}(\mathbf{x}_t, t) = \epsilon_{\theta}(\mathbf{x}_t, t) - \sqrt{1-\bar{\alpha}_t} \nabla_{\mathbf{x}_t} \log f_{\phi}(y|\mathbf{x}_t) \quad (11)$$

为了控制分类器引导的强度，我们引入一个超参数 w （称为 guidance scale），修改为：

$$\tilde{\epsilon}_{\theta}(\mathbf{x}_t, t) = \epsilon_{\theta}(\mathbf{x}_t, t) - \sqrt{1-\bar{\alpha}_t} * w * \nabla_{\mathbf{x}_t} \log f_{\phi}(y|\mathbf{x}_t) \quad (12)$$

从classifier-guidance的推导过程来看，我们需要训练一个分类器（Classifier）来提供类别条件下的梯度信息，以便在扩散模型的采样过程中引导生成特定类别的样本，并确保生成内容更加符合目标类别特征。

Classifier-free Guidance

classifier-free guidance的目的是去掉独立分类器，用同一个扩散模型实现条件引导，我们在上述的classifier-guidance中，我们需要一个额外、独立训练的分类器来提交梯度，从而引导生成过程。这样做的缺点是需要单独训练分类器，成本比较大。

而classifier-free guidance提出了一个更优雅解决方法：

- 不需要独立分类器
- 使用同一个神经网络同时学习无条件条件和条件生成
- 在训练时随机丢弃类别信息，让模型学会“如何无条件生成”。
- 在采样时，通过条件得分与无条件得分的差值来实现引导。

具体的推导过程如下：

- 首先classifier-guidance的核心公式为：

$$\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t|y) = \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t) + \nabla_{\mathbf{x}_t} \log q(y|\mathbf{x}_t) \quad (13)$$

我们将隐式分类器的梯度表示为，这也是CFG的理论基础：

$$\nabla_{\mathbf{x}_t} \log q(y|\mathbf{x}_t) = \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t|y) - \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t) \quad (14)$$

因为：

$$\log q(y|x_t) = \log q(x_t|y) - \log q(x_t) + \log q(y) \quad (15)$$

代入公式得到：

$$\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t|y) = \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t) + [\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t|y) - \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t)] \quad (16)$$

两边乘上系数 $-\sqrt{1-\bar{\alpha}_t}$ ：

$$\tilde{\epsilon}_{\theta}(\mathbf{x}_t, t, y) = \epsilon_{\theta}(\mathbf{x}_t, t, y) - \sqrt{1-\bar{\alpha}_t} w (\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t|y) - \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t)) \quad (17)$$

又因为 $\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t|y) \approx -\frac{1}{\sqrt{1-\bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t, y)$ 和 $\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t) \approx -\frac{1}{\sqrt{1-\bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t, \emptyset)$ ，所以：

$$\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t|y) - \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t) \approx -\frac{1}{\sqrt{1-\bar{\alpha}_t}} (\epsilon_{\theta}(\mathbf{x}_t, t, y) - \epsilon_{\theta}(\mathbf{x}_t, t, \emptyset)) \quad (18)$$

代入CFG公示后得到：

$$\tilde{\epsilon}_{\theta}(\mathbf{x}_t, t, y) = \epsilon_{\theta}(\mathbf{x}_t, t, y) - \sqrt{1-\bar{\alpha}_t} w \left(-\frac{1}{\sqrt{1-\bar{\alpha}_t}} (\epsilon_{\theta}(\mathbf{x}_t, t, y) - \epsilon_{\theta}(\mathbf{x}_t, t, \emptyset)) \right)$$

化简得到：

$$\tilde{\epsilon}_{\theta}(\mathbf{x}_t, t, y) = \epsilon_{\theta}(\mathbf{x}_t, t, y) + w (\epsilon_{\theta}(\mathbf{x}_t, t, y) - \epsilon_{\theta}(\mathbf{x}_t, t, \emptyset)) \quad (19)$$

最终的CFG公示为：

$$\tilde{\epsilon}_{\theta}(\mathbf{x}_t, t, y) = (w + 1)\epsilon_{\theta}(\mathbf{x}_t, t, y) - w\epsilon_{\theta}(\mathbf{x}_t, t, \emptyset) \quad (20)$$

classifier-guidance vs classifier-free guidance

