

Score Diffusion Models

xinli*

February 23, 2026

Contents

1	Score and Naive Score-Based Models	2
1.1	Score	2
1.2	Sampling with Langevin Dynamics	2
1.3	Score Matching	2
1.4	Denoising Score Matching	3
1.5	Challenges of Denoising Score Matching	3
2	Noise Conditional Score Network(NCSN)	4
2.1	Definition of NCSN	4
2.2	Learning NCSN via Score Matching	5
2.3	NCSN inference via annealed Langevin dynamics	5
2.3.1	步长选择 (Step size selection)	6
3	Score-based generative modeling with stochastic differential equations(SDEs)	7
3.1	Perturbing Data with an SDE	7
3.2	Reversing the SDE for sample generation	8
3.3	Estimating the reverse SDE with denoising score matching	8
3.4	Unifying SMLD and DDPM through SDEs	9

*<https://github.com/xinli2008>

1 Score and Naive Score-Based Models

1.1 Score

在介绍生成模型之前，首先需要定义什么是“分数”。假设数据集由来自未知数据分布 $p_{\text{data}}(\mathbf{x})$ 的独立同分布样本组成。概率密度 $p(\mathbf{x})$ 的分数定义为 $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ 。分数网络 $s_{\theta} : \mathbb{R}^D \rightarrow \mathbb{R}^D$ 是一个由 θ 参数化的神经网络，用于近似 $p_{\text{data}}(\mathbf{x})$ 的分数。生成建模的目标是利用数据集学习一个模型，用于从 $p_{\text{data}}(\mathbf{x})$ 生成新样本。基于分数的生成建模框架有两个要素：分数匹配和郎之万动力学。

1.2 Sampling with Langevin Dynamics

定义了分数之后，如何利用它来生成样本呢？郎之万动力学 (Langevin dynamics) 提供了一种仅利用分数函数 $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ 就能从概率密度 $p(\mathbf{x})$ 中生成样本的方法。给定固定的步长 $\epsilon > 0$ 和初始值 $\tilde{\mathbf{x}}_0 \sim \pi(\mathbf{x})$ (其中 π 是先验分布)，郎之万方法递归地计算以下公式：

$$\tilde{\mathbf{x}}_t = \tilde{\mathbf{x}}_{t-1} + \frac{\epsilon}{2} \nabla_{\mathbf{x}} \log p(\tilde{\mathbf{x}}_{t-1}) + \sqrt{\epsilon} \mathbf{z}_t$$

其中 $\mathbf{z}_t \sim \mathcal{N}(0, I)$ 。

当 $\epsilon \rightarrow 0$ 且 $T \rightarrow \infty$ 时， $\tilde{\mathbf{x}}_T$ 的分布等于 $p(\mathbf{x})$ ，此时 $\tilde{\mathbf{x}}_T$ 成为 $p(\mathbf{x})$ 的精确样本 (在某些正则条件下)。当 $\epsilon > 0$ 且 $T < \infty$ 时，需要 Metropolis-Hastings 更新来校正误差，但在实践中通常可以忽略。通常假设当 ϵ 很小且 T 很大时，该误差可以忽略不计。

注意，从上述公式采样仅需要分数函数 $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ 。因此，为了从 $p_{\text{data}}(\mathbf{x})$ 获得样本，可以首先训练分数网络使得 $s_{\theta}(\mathbf{x}) \approx \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$ ，然后使用 $s_{\theta}(\mathbf{x})$ 通过郎之万动力学近似获得样本。这是基于分数的生成建模框架的关键思想。

1.3 Score Matching

为了使用郎之万动力学采样，我们需要知道数据分布的分数函数。然而，真实的数据分布是未知的，因此需要一种方法从数据中学习分数函数。分数匹配 (Score matching) 最初是为了基于来自未知数据分布的独立同分布样本学习非归一化统计模型而设计的。该方法被重新用于分数估计。利用分数匹配，可以直接训练一个分数网络 $s_{\theta}(\mathbf{x})$ 来估计 $\nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$ ，而无需先训练一个模型来估计 $p_{\text{data}}(\mathbf{x})$ 。与分数匹配的典型用法不同，这里选择不使用基于能量的模型的梯度作为分数网络，以避免计算高阶梯度带来的额外计算量。目标是最小化

$$\frac{1}{2} \mathbb{E}_{p_{\text{data}}} [\|s_{\theta}(\mathbf{x}) - \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})\|_2^2]$$

这可以证明等价于 (差一个常数)：

$$\mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left[\text{tr}(\nabla_{\mathbf{x}} s_{\theta}(\mathbf{x})) + \frac{1}{2} \|s_{\theta}(\mathbf{x})\|_2^2 \right]$$

其中 $\nabla_{\mathbf{x}} s_{\theta}(\mathbf{x})$ 表示 $s_{\theta}(\mathbf{x})$ 的雅可比矩阵。如文献所示，在某些正则条件下，使得上式最小化的 $s_{\theta^*}(\mathbf{x})$ 几乎处处满足 $s_{\theta^*}(\mathbf{x}) = \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$ 。

在实践中，可以通过数据样本快速估计期望。然而，由于需要计算 $\text{tr}(\nabla_{\mathbf{x}} s_{\theta}(\mathbf{x}))$ ，分数匹配难以扩展到深度网络和高维数据。下面讨论另外一种用于大规模分数匹配的流行方法：去噪分数匹配 (Denoising score matching)。

1.4 Denoising Score Matching

标准的分数匹配计算量大，难以扩展。为了解决这个问题，去噪分数匹配 (Denoising score matching) 作为一种变体被提出，它完全避开了 $\text{tr}(\nabla_{\mathbf{x}} s_{\theta}(\mathbf{x}))$ 的计算。它首先使用预先指定的噪声分布 $q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x})$ 对数据点 $\mathbf{x}$ 进行扰动，然后利用分数匹配来估计扰动后数据分布 $q_{\sigma}(\tilde{\mathbf{x}}) \triangleq \int q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x})p_{\text{data}}(\mathbf{x})d\mathbf{x}$ 的分数。该目标函数被证明等价于：

$$\frac{1}{2}\mathbb{E}_{q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x})p_{\text{data}}(\mathbf{x})}[\|s_{\theta}(\tilde{\mathbf{x}}) - \nabla_{\tilde{\mathbf{x}}} \log q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x})\|_2^2]$$

如文献所示，最小化上式的最优分数网络 (记为 $s_{\theta^*}(\mathbf{x})$) 几乎处处满足 $s_{\theta^*}(\mathbf{x}) = \nabla_{\mathbf{x}} \log q_{\sigma}(\mathbf{x})$ 。然而，只有当噪声足够小使得 $q_{\sigma}(\mathbf{x}) \approx p_{\text{data}}(\mathbf{x})$ 时， $s_{\theta^*}(\mathbf{x}) = \nabla_{\mathbf{x}} \log q_{\sigma}(\mathbf{x}) \approx \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$ 才成立。

1.5 Challenges of Denoising Score Matching

虽然去噪分数匹配解决了计算效率问题，但在实际应用中，特别是在高维数据上，它仍然面临着挑战。




Figure 1: Challenges of Denoising Score Matching

在高维空间中，当使用郎之万动力学进行采样时，初始样本极有可能位于数据密度较低的区域。因此，如果基于分数的模型在这些区域的估计不准确，就会导致郎之万动力学从一开始就偏离正确的轨迹，从而无法生成能够代表数据的高质量样本。简而言之，在数据密度较低的区域，分数估计往往不准确，这会导致郎之万采样的误差进一步放大，最终影响生成效果。

上图直观地展示了这一问题：

- Data density(数据密度)：左图展示了真实数据的分布，主要集中在两个高密度区域 (右上和左下)。其余区域数据密度极低或为零。
- Data scores(真实分数)：中图展示了理论上的真实分数函数 ($\nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$)。可以看到，箭头都指向高密度区域。
- Estimated scores(估计分数)：右图展示了模型学习到的分数函数。
 - 在高密度区域 (绿色框内)，模型有充足的训练数据，因此估计的分数非常准确 (Accurate)，箭头方向与真实分数一致。

- 在低密度区域 (红色背景区域), 由于缺乏训练数据, 模型无法学习到正确的分数, 导致估计的分数非常不准确 (Inaccurate), 箭头方向杂乱无章, 并未指向高密度区域。

这就解释了为什么从低密度区域开始的郎之万采样容易失败: 采样过程依赖分数指引方向, 而起步阶段的分数指引就是错误的。

2 Noise Conditional Score Network(NCSN)

为了解决低密度区域分数估计不准确的问题, NCSN 引入了多尺度噪声扰动的策略。




Figure 2: Noise Conditional Score Network(NCSN)

为了解决上述挑战, 需要权衡噪声尺度的选择:

- 两难之处:
 - 大噪声: 可以覆盖更多的低密度区域, 从而获得更好的分数估计, 但会严重破坏数据, 使其显著偏离原始分布。
 - 小噪声: 对原始数据分布的破坏较小, 但无法像希望的那样覆盖低密度区域。
- 最佳平衡方案 (NCSN): 为了兼得两者的优点, 同时使用多个尺度的噪声扰动。具体来说:
 1. 使用不同级别的噪声对数据进行扰动。
 2. 通过训练单个条件分数网络 (Conditional Score Network), 同时估计对应于所有噪声级别的分数。

在训练完成后, 当使用郎之万动力学生成样本时, 最初使用对应于大噪声的分数, 然后逐渐降低噪声级别 (退火)。这有助于将大噪声级别的好处平滑地转移到小噪声级别, 而在小噪声级别下, 扰动后的数据与原始数据几乎无法区分。

上图展示了这一策略的效果: 通过多尺度噪声扰动, 模型能够在所有区域 (包括原本的低密度区域) 都获得准确的分数估计 (Accurate), 从而为郎之万采样提供正确的指引。

2.1 Definition of NCSN

基于上述思想, 我们可以正式定义噪声条件分数网络 (NCSN)。令 $\{\sigma_i\}_{i=1}^L$ 为一个正的几何数列, 满足 $\frac{\sigma_1}{\sigma_2} = \dots = \frac{\sigma_{L-1}}{\sigma_L} > 1$ 。令 $q_\sigma(\mathbf{x}) \triangleq \int p_{\text{data}}(\mathbf{t}) \mathcal{N}(\mathbf{x}|\mathbf{t}, \sigma^2 I) d\mathbf{t}$ 表示扰动后的数据分布。噪

声水平 $\{\sigma_i\}_{i=1}^L$ 的选择应使得 σ_1 足够大以缓解低密度区域的困难，而 σ_L 足够小以最小化对数据的影响。目标是训练一个条件分数网络来联合估计所有扰动数据分布的分数，即 $\forall \sigma \in \{\sigma_i\}_{i=1}^L : s_{\theta}(\mathbf{x}, \sigma) \approx \nabla_{\mathbf{x}} \log q_{\sigma}(\mathbf{x})$ 。注意，当 $\mathbf{x} \in \mathbb{R}^D$ 时， $s_{\theta}(\mathbf{x}, \sigma) \in \mathbb{R}^D$ 。 $s_{\theta}(\mathbf{x}, \sigma)$ 被称为噪声条件分数网络 (Noise Conditional Score Network, NCSN)。

与基于似然的生成模型和 GAN 类似，模型架构的设计在生成高质量样本中起着重要作用。这项工作主要关注对图像生成有用的架构。由于噪声条件分数网络 $s_{\theta}(\mathbf{x}, \sigma)$ 的输出与输入图像 $\mathbf{x}$ 具有相同的形状，因此借鉴了用于图像密集预测 (例如语义分割) 的成功模型架构。实验模型 $s_{\theta}(\mathbf{x}, \sigma)$ 结合了 U-Net 的架构设计与空洞/扩张卷积 (dilated/atrous convolution)——这两者都在语义分割中被证明非常成功。此外，受其在一些图像生成任务中优越性能的启发，在分数网络中采用了实例归一化 (instance normalization)。

2.2 Learning NCSN via Score Matching

定义了 NCSN 之后，接下来的问题是如何训练它。虽然切片分数匹配 (Sliced Score Matching) 和去噪分数匹配 (Denoising Score Matching) 都可以用来训练 NCSN，但这里采用去噪分数匹配，因为它速度稍快，且天然适合估计噪声扰动数据分布的分数这一任务。

选择噪声分布为 $q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) = \mathcal{N}(\tilde{\mathbf{x}}|\mathbf{x}, \sigma^2 I)$ ；因此 $\nabla_{\tilde{\mathbf{x}}} \log q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) = -(\tilde{\mathbf{x}} - \mathbf{x})/\sigma^2$ 。对于给定的 σ ，去噪分数匹配的目标函数为：

$$\ell(\theta; \sigma) \triangleq \frac{1}{2} \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \mathbb{E}_{\tilde{\mathbf{x}} \sim \mathcal{N}(\mathbf{x}, \sigma^2 I)} \left[\left\| s_{\theta}(\tilde{\mathbf{x}}, \sigma) + \frac{\tilde{\mathbf{x}} - \mathbf{x}}{\sigma^2} \right\|_2^2 \right]$$

然后，将所有 $\sigma \in \{\sigma_i\}_{i=1}^L$ 的目标函数组合起来，得到一个统一的目标函数：

$$\mathcal{L}(\theta; \{\sigma_i\}_{i=1}^L) \triangleq \frac{1}{L} \sum_{i=1}^L \lambda(\sigma_i) \ell(\theta; \sigma_i)$$

其中 $\lambda(\sigma_i) > 0$ 是依赖于 σ_i 的系数函数。假设 $s_{\theta}(\mathbf{x}, \sigma)$ 具有足够的容量， $s_{\theta^*}(\mathbf{x}, \sigma)$ 最小化上式当且仅当对于所有 $i \in \{1, 2, \dots, L\}$ ， $s_{\theta^*}(\mathbf{x}, \sigma_i) = \nabla_{\mathbf{x}} \log q_{\sigma_i}(\mathbf{x})$ 几乎处处成立。

关于 $\lambda(\cdot)$ 的选择有很多种可能。理想情况下，希望对于所有 $\{\sigma_i\}_{i=1}^L$ ， $\lambda(\sigma_i) \ell(\theta; \sigma_i)$ 的值都在大致相同的数量级上。经验上，研究观察到当分数网络训练到最优时，大约有 $\|s_{\theta}(\mathbf{x}, \sigma)\|_2 \propto 1/\sigma$ 。这启发我们选择 $\lambda(\sigma) = \sigma^2$ 。因为在这种选择下，有 $\lambda(\sigma) \ell(\theta; \sigma) = \sigma^2 \ell(\theta; \sigma) = \frac{1}{2} \mathbb{E}[\|s_{\theta}(\tilde{\mathbf{x}}, \sigma) + \frac{\tilde{\mathbf{x}} - \mathbf{x}}{\sigma}\|_2^2]$ 。由于 $\frac{\tilde{\mathbf{x}} - \mathbf{x}}{\sigma} \sim \mathcal{N}(0, I)$ 且 $\|s_{\theta}(\mathbf{x}, \sigma)\|_2 \propto 1$ ，可以很容易地得出结论： $\lambda(\sigma) \ell(\theta; \sigma)$ 的数量级不依赖于 σ 。

2.3 NCSN inference via annealed Langevin dynamics

训练好 NCSN 后，我们需要一种新的采样方法来利用多尺度的分数信息。为此，提出了一种采样方法——退火郎之万动力学 (annealed Langevin dynamics, 算法 1)——来生成样本。这种方法受模拟退火和退火重要性采样的启发。

如算法 1 所示，退火郎之万动力学的过程如下：

1. 初始化：从某个固定的先验分布 (例如均匀噪声) 中初始化样本 $\tilde{\mathbf{x}}_0$ 。
2. 退火循环：从最大噪声水平 σ_1 开始，逐步过渡到最小噪声水平 σ_L 。

Algorithm 1 Annealed Langevin dynamics.

Require: $\{\sigma_i\}_{i=1}^L, \epsilon, T$.

- 1: Initialize $\tilde{\mathbf{x}}_0$
- 2: **for** $i \leftarrow 1$ to L **do**
- 3: $\alpha_i \leftarrow \epsilon \cdot \sigma_i^2 / \sigma_L^2$ $\triangleright \alpha_i$ is the step size.
- 4: **for** $t \leftarrow 1$ to T **do**
- 5: Draw $\mathbf{z}_t \sim \mathcal{N}(0, I)$
- 6: $\tilde{\mathbf{x}}_t \leftarrow \tilde{\mathbf{x}}_{t-1} + \frac{\alpha_i}{2} \mathbf{s}_\theta(\tilde{\mathbf{x}}_{t-1}, \sigma_i) + \sqrt{\alpha_i} \mathbf{z}_t$
- 7: **end for**
- 8: $\tilde{\mathbf{x}}_0 \leftarrow \tilde{\mathbf{x}}_T$
- 9: **end for**
- return** $\tilde{\mathbf{x}}_T$

Figure 3: NCSN inference via annealed Langevin dynamics

3. 郎之万动力学更新:

- 对于每个噪声水平 σ_i , 运行 T 步郎之万动力学来从 $q_{\sigma_i}(\mathbf{x})$ 中采样。
- 步长调整: 步长 α_i 随着噪声水平 σ_i 的减小而减小, 具体设置为 $\alpha_i = \epsilon \cdot \sigma_i^2 / \sigma_L^2$ 。
- 状态继承: 上一轮噪声水平 σ_{i-1} 的最终样本作为当前噪声水平 σ_i 的初始样本。

4. 最终输出: 随着噪声水平逐渐降低, 最终运行郎之万动力学从 $q_{\sigma_L}(\mathbf{x})$ 中采样。当 $\sigma_L \approx 0$ 时, $q_{\sigma_L}(\mathbf{x})$ 非常接近原始数据分布 $p_{\text{data}}(\mathbf{x})$, 因此最终得到的 $\tilde{\mathbf{x}}_T$ 就是高质量的数据样本。

这种方法通过从大噪声开始, 利用大噪声下准确的分数估计将样本引导至高密度区域, 然后随着噪声减小逐步精细化, 从而解决了标准郎之万动力学在低密度区域失效的问题。

2.3.1 步长选择 (Step size selection)

在算法 1 中, 关于如何根据 σ_i 调整 α_i 有多种可能的方法。这里选择 $\alpha_i \propto \sigma_i^2$ 。

这样做的动机是为了固定郎之万动力学中“信噪比 (signal-to-noise ratio)”的量级。郎之万动力学的更新公式为:

$$\tilde{\mathbf{x}}_t \leftarrow \tilde{\mathbf{x}}_{t-1} + \frac{\alpha_i}{2} \mathbf{s}_\theta(\tilde{\mathbf{x}}_{t-1}, \sigma_i) + \sqrt{\alpha_i} \mathbf{z}_t$$

其中信号项为 $\frac{\alpha_i}{2} \mathbf{s}_\theta(\tilde{\mathbf{x}}_{t-1}, \sigma_i)$, 噪声项为 $\sqrt{\alpha_i} \mathbf{z}_t$ 。信噪比可以表示为 $\frac{\alpha_i \mathbf{s}_\theta(\mathbf{x}, \sigma_i)}{2\sqrt{\alpha_i} \mathbf{z}}$ 。

注意到:

$$\mathbb{E} \left[\left\| \frac{\alpha_i \mathbf{s}_\theta(\mathbf{x}, \sigma_i)}{2\sqrt{\alpha_i} \mathbf{z}} \right\|_2^2 \right] \approx \mathbb{E} \left[\frac{\alpha_i \|\mathbf{s}_\theta(\mathbf{x}, \sigma_i)\|_2^2}{4} \right] \propto \frac{1}{4} \mathbb{E} [\|\sigma_i \mathbf{s}_\theta(\mathbf{x}, \sigma_i)\|_2^2]$$

回想一下, 经验上发现当分数网络训练接近最优时, 有 $\|\mathbf{s}_\theta(\mathbf{x}, \sigma)\|_2 \propto 1/\sigma$ 。在这种情况下, $\mathbb{E} [\|\sigma_i \mathbf{s}_\theta(\mathbf{x}, \sigma_i)\|_2^2] \propto 1$ 。

因此, 如果选择 $\alpha_i \propto \sigma_i^2$, 那么信噪比的量级 $\left\| \frac{\alpha_i \mathbf{s}_\theta(\mathbf{x}, \sigma_i)}{2\sqrt{\alpha_i} \mathbf{z}} \right\|_2 \propto \frac{1}{4} \mathbb{E} [\|\sigma_i \mathbf{s}_\theta(\mathbf{x}, \sigma_i)\|_2^2] \propto \frac{1}{4}$ 将不依赖于 σ_i 。这意味着在整个退火过程中, 信号和噪声的相对强度保持恒定, 从而保证了采样的稳定性。

3 Score-based generative modeling with stochastic differential equations(SDEs)

NCSN 使用了有限数量的噪声尺度。如果将这一思想推向极限，即噪声尺度的数量推广到无穷大，我们就能得到一个连续的扩散过程。这不仅能获得更高质量的样本，还能实现精确的对数似然计算和可控生成等功能。这就是基于随机微分方程 (SDE) 的生成建模方法。




Figure 1: **Solving a reverse-time SDE yields a score-based generative model.** Transforming data to a simple noise distribution can be accomplished with a continuous-time SDE. This SDE can be reversed if we know the score of the distribution at each intermediate time step, $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$.

Figure 4: Score-based generative modeling with SDEs

3.1 Perturbing Data with an SDE

为了使用基于分数的模型生成样本，首先需要定义一个前向过程，将数据缓慢破坏为随机噪声。这个过程可以被建模为一个扩散过程 (diffusion process)。生成样本的过程则是该扩散过程的逆过程。

扩散过程是一个类似于布朗运动 (Brownian motion) 的随机过程。设 $\{\mathbf{x}(t) \in \mathbb{R}^D\}_{t=0}^T$ 为一个由连续时间变量 $t \in [0, T]$ 索引的扩散过程。该过程由以下形式的随机微分方程 (SDE) 控制：

$$d\mathbf{x} = \mathbf{f}(\mathbf{x}, t)dt + g(t)d\mathbf{w}$$

其中：

- $\mathbf{f}(\cdot, t) : \mathbb{R}^D \rightarrow \mathbb{R}^D$ ：称为漂移系数 (drift coefficient)。它代表了确定性的运动趋势。
- $g(t) \in \mathbb{R}$ ：称为扩散系数 (diffusion coefficient)。它控制了随机噪声的影响强度。
- $\mathbf{w}$ ：代表标准布朗运动 (standard Brownian motion)。

可以将 SDE 理解为常微分方程 (ODE) 的随机推广。粒子的运动不仅遵循确定性的漂移 $\mathbf{f}(\mathbf{x}, t)$ ，还受到来自 $g(t)d\mathbf{w}$ 的随机噪声的影响。此处使用 $p_t(\mathbf{x})$ 来表示 $\mathbf{x}(t)$ 的分布。

对于基于分数的生成建模，选择的扩散过程需满足以下边界条件：

- $\mathbf{x}(0) \sim p_0$ ： p_0 是数据分布 (即我们拥有的独立同分布样本集)。
- $\mathbf{x}(T) \sim p_T$ ： p_T 是先验分布 (通常是易于采样的形式，如高斯分布)。
- 条件：扩散过程的噪声扰动必须足够大，以确保 p_T 不依赖于 p_0 (即最终完全变成了纯噪声，与原始数据无关)。

3.2 Reversing the SDE for sample generation

定义了前向扩散过程后，生成样本的关键在于如何反转这个过程。从先验分布 p_T 中采样，并反转扩散过程，就能够获得来自数据分布 p_0 的样本。关键在于，反向过程也是一个扩散过程，只是在时间上是倒退的。它由以下逆时间 SDE(reverse-time SDE) 给出：

$$d\mathbf{x} = [\mathbf{f}(\mathbf{x}, t) - g^2(t)\nabla_{\mathbf{x}} \log p_t(\mathbf{x})]dt + g(t)d\bar{\mathbf{w}}$$

其中：

- $\bar{\mathbf{w}}$ ：是一个逆时间方向的布朗运动。
- dt ：代表一个无穷小的负时间步长（因为时间是倒流的）。

一旦知道了前向 SDE 的漂移系数 $\mathbf{f}(\mathbf{x}, t)$ 和扩散系数 $g(t)$ ，以及每个时刻 $t \in [0, T]$ 的分数 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ ，就可以计算出这个逆向 SDE。

基于分数的 SDE 生成建模的整体直觉可以总结为：

1. 前向过程 (Forward SDE)：通过 SDE 将数据分布 p_0 逐渐破坏为先验分布 p_T (纯噪声)。
2. 分数估计：训练一个分数网络来估计每个时刻的分数 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 。
3. 反向过程 (Reverse SDE)：利用估计的分数，通过数值求解逆向 SDE，从先验分布 p_T 中采样并逐步恢复出数据分布 p_0 。

3.3 Estimating the reverse SDE with denoising score matching

为了解逆向 SDE，我们需要估计时间依赖的分数函数 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 。基于上述直觉，可以使用时间依赖的分数函数 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 来构建逆时间 SDE，然后通过数值求解，利用来自完全可处理的先验分布 p_T 的样本来获得 p_0 的样本。

可以训练一个时间依赖的基于分数的模型 $s_{\theta}(\mathbf{x}, t)$ 来近似 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 。训练目标是去噪分数匹配目标的加权和：

$$\min_{\theta} \mathbb{E}_{t \sim \mathcal{U}(0, T)} [\lambda(t) \mathbb{E}_{\mathbf{x}(0) \sim p_0(\mathbf{x})} \mathbb{E}_{\mathbf{x}(t) \sim p_{0t}(\mathbf{x}(t)|\mathbf{x}(0))} [\|s_{\theta}(\mathbf{x}(t), t) - \nabla_{\mathbf{x}(t)} \log p_{0t}(\mathbf{x}(t)|\mathbf{x}(0))\|_2^2]]$$

其中：

- $\mathcal{U}(0, T)$ 是 $[0, T]$ 上的均匀分布。
- $p_{0t}(\mathbf{x}(t)|\mathbf{x}(0))$ 表示从 $\mathbf{x}(0)$ 到 $\mathbf{x}(t)$ 的转移概率。
- $\lambda(t) \in \mathbb{R}_{>0}$ 表示正的权重函数。

在目标函数中：

- 对 $\mathbf{x}(0)$ 的期望可以通过 p_0 中数据样本的经验均值来估计。
- 对 $\mathbf{x}(t)$ 的期望可以通过从 $p_{0t}(\mathbf{x}(t)|\mathbf{x}(0))$ 中采样来估计。当漂移系数 $\mathbf{f}(\mathbf{x}, t)$ 是仿射变换时，这种采样是高效的。
- 权重函数 $\lambda(t)$ 通常选择与 $\frac{1}{\mathbb{E}[\|\nabla_{\mathbf{x}} \log p_{0t}(\mathbf{x}(t)|\mathbf{x}(0))\|_2^2]}$ 成正比（如果是高斯分布，这对应于方差的倒数），以平衡不同时间步长上分数匹配损失的量级。

3.4 Unifying SMLD and DDPM through SDEs

基于分数的生成模型 (如 SMLD) 和去噪扩散概率模型 (如 DDPM) 看似是两种不同的生成方法,但在连续时间的视角下,它们实际上都可以被统一到同一个 SDE 框架中。具体而言,这两种方法中所使用的离散噪声扰动过程,可以分别看作是两个不同连续时间 SDE 的离散化形式。

1. SMLD 与方差爆炸 SDE (Variance Exploding SDE)

在 SMLD 中,给定总共 N 个噪声尺度,其每一个扰动核 $p_{\sigma_i}(\mathbf{x}|\mathbf{x}_0)$ 对应于以下离散马尔可夫链:

$$\mathbf{x}_i = \mathbf{x}_{i-1} + \sqrt{\sigma_i^2 - \sigma_{i-1}^2} \mathbf{z}_{i-1}, \quad i = 1, \dots, N$$

其中 $\mathbf{z}_{i-1} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。当取极限 $N \rightarrow \infty$ 时,离散的时间步长变成连续变量 $t \in [0, 1]$,上述马尔可夫链收敛为以下连续随机过程:

$$d\mathbf{x} = \sqrt{\frac{d[\sigma^2(t)]}{dt}} d\mathbf{w}$$

由于该 SDE (其漂移系数为 0) 随着时间 t 增加始终会产生一个方差爆炸的过程,因此被称为**方差爆炸 (Variance Exploding, VE) SDE**。

2. DDPM 与方差保持 SDE (Variance Preserving SDE)

类似地,对于 DDPM 中使用的扰动核 $\{p_{\alpha_i}(\mathbf{x}|\mathbf{x}_0)\}_{i=1}^N$,其离散马尔可夫链为:

$$\mathbf{x}_i = \sqrt{1 - \beta_i} \mathbf{x}_{i-1} + \sqrt{\beta_i} \mathbf{z}_{i-1}, \quad i = 1, \dots, N$$

当 $N \rightarrow \infty$ 时,该过程收敛为以下 SDE:

$$d\mathbf{x} = -\frac{1}{2}\beta(t)\mathbf{x}dt + \sqrt{\beta(t)}d\mathbf{w}$$

与 VE SDE 不同,如果初始分布具有单位方差,该 SDE 会产生一个方差固定为 1 的过程。因为这一特性,它被称为**方差保持 (Variance Preserving, VP) SDE**。

3. 为什么它们是两种不同的 SDE ?

通过上述推导可以清晰地看出, SMLD 和 DDPM 虽然同为扩散过程,但它们对应着物理机制完全不同的两种 SDE:

- **方差演变机制的不同:** SMLD 在每一步仅单纯地添加噪声,而不衰减原始信号,导致过程的总方差无限制地趋于无穷大 (对应 SDE 中漂移项为 0)。相反, DDPM 在添加噪声的同时,会按比例 (即 $\sqrt{1 - \beta_i}$) 缩小前一时刻的状态。这种机制在连续极限下表现为一个负的漂移项 $-\frac{1}{2}\beta(t)\mathbf{x}$, 它如同一个向原点拉扯的力,使得整个扰动过程的方差始终保持在有界范围内 (即方差保持)。因此, SMLD 对应的是方差爆炸 (Variance Exploding, VE) SDE, 而 DDPM 对应的是方差保持 (Variance Preserving, VP) SDE。
- **统一视角的意义:** 将其统一在 SDE 框架下,不仅从连续数学的本质解释了它们为何会分别走向“方差爆炸”与“方差保持”,还为设计全新的前向扰动过程 (例如方差上限更严格的 Sub-VP SDE) 提供了稳固的理论基础。